INSTITUTO TECNOLÓGICO DE MORELIA

INTELIGENCIA ARTIFICIAL

Actividad preguntas redes neuronales y árboles de decisión

INGENIERÍA EN SISTEMAS COMPUTACIONALES

PRESENTA:

22121316 Hernández Alvarado Axel Joshua

PROFESOR:

JESUS EDUARDO ALCARAZ CHAVEZ

MORELIA, MICHOACÁN **Octubre, 2026**

Parte I. Conceptos y definiciones

Pregunta 1

¿Qué es un árbol de decisión y cuál es su objetivo principal dentro de un problema de clasificación?

Un árbol de decisión es un modelo de aprendizaje supervisado que toma decisiones mediante una serie de preguntas o condiciones sobre los datos. Está formado por nodos, ramas y hojas.

Su objetivo principal en un problema de clasificación es utilizar las características de los datos para determinar a qué clase pertenece un elemento. Por ejemplo, puede decidir si una persona tiene riesgo de aprobar o reprobar una materia dependiendo de su asistencia, calificaciones y tareas.

Una de sus principales ventajas es que resulta fácil de interpretar, ya que se pueden seguir las decisiones desde la raíz hasta una hoja y entender por qué se obtuvo determinado resultado.

Pregunta 2

Explique con sus propias palabras los siguientes elementos de un árbol de decisión:

- **Nodo raíz:** Es el punto donde comienza el árbol. Representa la primera pregunta o condición que se utiliza para dividir los datos.
- **Nodo interno:** Es un punto intermedio del árbol donde se realiza otra pregunta o condición para continuar dividiendo los datos.
- **Rama:** Es la conexión entre los nodos y representa el resultado de una condición. Por ejemplo, una rama podría representar "sí" y otra "no".
- **Hoja:** Es el punto final del árbol. Contiene la decisión o clasificación que se obtiene después de seguir las diferentes condiciones.

En resumen, el árbol comienza en la raíz, pasa por diferentes nodos internos y ramas, y finalmente llega a una hoja que proporciona la predicción.

Pregunta 3

¿Qué es una red neuronal multicapa y qué función cumplen sus capas?

Una red neuronal multicapa es un modelo de aprendizaje automático formado por varias capas de neuronas conectadas entre sí. Estas conexiones tienen

pesos que se ajustan durante el entrenamiento para que la red pueda aprender patrones en los datos.

Sus principales capas son:

- **Capa de entrada:** Recibe los datos que se proporcionan al modelo. Por ejemplo, en un sistema para detectar riesgo académico podría recibir asistencia, calificaciones y número de tareas entregadas.
- **Capa oculta:** Procesa la información recibida y aprende relaciones o patrones más complejos entre las características. Una red puede tener una o varias capas ocultas.
- **Capa de salida:** Produce el resultado final de la red. Por ejemplo, puede indicar si un estudiante tiene riesgo de reprobar o no.

Pregunta 4

¿Qué representan los pesos y los sesgos dentro de una red neuronal? Explique también por qué sus valores cambian durante el entrenamiento.

Los **pesos** representan la importancia que tiene cada entrada para una neurona. Un peso alto puede hacer que determinada entrada tenga una mayor influencia sobre el resultado de la neurona.

El **sesgo** permite ajustar el resultado de una neurona independientemente de las entradas. Se puede entender como un valor adicional que ayuda a la red a adaptarse mejor a los datos.

Estos valores cambian durante el entrenamiento porque inicialmente la red no conoce la relación correcta entre los datos de entrada y las respuestas. La red realiza predicciones, calcula el error y utiliza la retropropagación y el descenso por gradiente para modificar los pesos y sesgos. De esta manera intenta reducir el error y mejorar sus predicciones.

Pregunta 5

¿Cuál es la principal diferencia entre la forma en que aprende un árbol de decisión y la forma en que aprende una red neuronal multicapa? Explique qué elementos aprende cada modelo.

La principal diferencia es que un **árbol de decisión aprende reglas de decisión**, mientras que una **red neuronal aprende los valores de sus pesos y sesgos** para encontrar patrones en los datos.

El árbol aprende qué características y condiciones utilizar para dividir los datos, por ejemplo: "si la calificación es menor a 70, entonces..." y continúa creando ramas hasta llegar a una clasificación.

En cambio, la red neuronal ajusta sus pesos y sesgos mediante el entrenamiento. Calcula el error de sus predicciones y utiliza la retropropagación para saber cómo modificar esos valores.

Por lo tanto, el árbol genera una estructura de decisiones que generalmente es fácil de interpretar, mientras que la red neuronal aprende una combinación de parámetros que puede representar relaciones más complejas, pero que normalmente es más difícil de interpretar.

Parte II. Análisis y aplicación

Pregunta 6

Una institución bancaria desea desarrollar un sistema que detecte posibles compras fraudulentas. Analice las ventajas y desventajas de utilizar un árbol de decisión y una red neuronal multicapa. ¿Cuál utilizaría y por qué?

Un **árbol de decisión** tendría como ventaja que es fácil de interpretar. Se podría saber por qué una compra fue considerada sospechosa, por ejemplo, si el monto es muy alto, se realizó en una ciudad diferente y además existe un número inusual de compras durante el día.

Otra ventaja es que puede trabajar con diferentes tipos de características y no necesita una estructura demasiado compleja. Sin embargo, puede tener problemas si los patrones de fraude son muy complejos y también puede sufrir sobreajuste si el árbol crece demasiado.

Una **red neuronal multicapa** podría aprender relaciones más complejas entre las diferentes características de las compras. Esto podría ser útil porque el fraude puede depender de una combinación de muchos factores. Como desventaja, puede ser más difícil explicar por qué una determinada compra fue clasificada como fraudulenta.

En este caso **utilizaría una red neuronal multicapa**, especialmente si se cuenta con una gran cantidad de datos históricos. La detección de fraude puede involucrar patrones complejos que una red neuronal podría aprender

mejor. Sin embargo, complementaría el sistema con herramientas de interpretación para poder analizar las decisiones importantes.

Pregunta 7

Una escuela quiere detectar estudiantes que presentan riesgo de reprobar una materia. Si ambos modelos obtienen prácticamente la misma precisión, ¿qué otros factores tomaría en cuenta?

Si ambos modelos tienen prácticamente la misma precisión, consideraría principalmente la **interpretabilidad**, el costo de entrenamiento, la facilidad de mantenimiento y la cantidad de datos disponibles.

En este caso probablemente elegiría el **árbol de decisión**, porque permitiría a los profesores entender fácilmente por qué el sistema considera que un estudiante está en riesgo. Por ejemplo, podrían observar que la decisión se debe principalmente a una baja asistencia y a varias tareas no entregadas.

Esto es importante porque los profesores podrían utilizar la información para tomar acciones concretas con el estudiante. Una red neuronal podría tener una precisión similar, pero sería más difícil explicar su razonamiento.

Por lo tanto, cuando el rendimiento es prácticamente igual, la facilidad de interpretación del árbol de decisión sería una ventaja importante.

Pregunta 8

Un hospital desarrolla un sistema para determinar qué pacientes necesitan atención prioritaria. Una red neuronal obtiene mejores resultados que un árbol de decisión, pero resulta más difícil explicar cómo obtuvo su respuesta. ¿Considera que la mayor precisión es suficiente para elegir la red neuronal?

No considero que la mayor precisión sea suficiente para elegir automáticamente la red neuronal.

En un hospital las decisiones pueden tener consecuencias importantes para los pacientes. Por esta razón no solamente importa que el modelo tenga una buena precisión, sino también que sea posible entender y revisar por qué tomó una determinada decisión.

Aunque la red neuronal tenga mejores resultados, su falta de interpretabilidad podría ser un problema si un médico necesita conocer las razones por las cuales un paciente fue clasificado como prioritario.

También habría que analizar otros factores, como los falsos positivos y falsos negativos. Un modelo podría tener una precisión general alta, pero cometer errores graves en ciertos tipos de pacientes.

Por lo tanto, antes de elegir la red neuronal compararía diferentes métricas y analizaría las consecuencias de sus errores. Si la diferencia de rendimiento fuera pequeña, podría ser preferible un modelo más interpretable.

Pregunta 9

Una empresa de reparto obtiene predicciones diferentes entre un árbol de decisión y una red neuronal. ¿Cómo determinaría cuál de los dos modelos está realizando una mejor predicción?

No determinaría cuál es mejor solamente comparando la predicción de ese pedido. Necesitaría conocer el resultado real del pedido y evaluar ambos modelos utilizando un conjunto de datos de prueba.

Por ejemplo, si finalmente el pedido llegó a tiempo, la predicción del árbol habría sido correcta y la de la red neuronal incorrecta. Si llegó tarde, ocurriría lo contrario.

Además, analizaría los resultados de muchos pedidos y utilizaría métricas como precisión, recall, matriz de confusión y, dependiendo del objetivo, otras métricas de clasificación.

También sería importante revisar qué tan bien funcionan los modelos con diferentes situaciones, como tráfico intenso, mal clima o grandes cantidades de pedidos.

Por lo tanto, el modelo que tenga un mejor desempeño general sobre datos que no haya visto durante el entrenamiento sería el candidato más adecuado, no necesariamente el que acertó en un solo pedido.

Pregunta 10

Una empresa desarrolla dos sistemas para decidir si una persona puede recibir un crédito. El primero utiliza un árbol de decisión y explica claramente por qué una solicitud fue rechazada. El segundo utiliza una

red neuronal multicapa y obtiene mejores resultados de predicción, pero es más difícil explicar sus decisiones. Si usted fuera responsable del proyecto, ¿qué consideraría?

Si fuera responsable del proyecto, no elegiría únicamente el modelo que tiene mayor precisión. Consideraría también la importancia de poder explicar las decisiones, especialmente porque se trata de una decisión financiera que afecta directamente a las personas.

El árbol de decisión tendría la ventaja de ser más fácil de interpretar. Si una solicitud es rechazada, podría explicarse que la decisión se debe, por ejemplo, a un determinado nivel de ingresos, historial crediticio o nivel de endeudamiento.

La red neuronal podría ser mejor en términos de predicción, pero si sus decisiones son difíciles de explicar, podría generar problemas para justificar los rechazos y detectar posibles errores o sesgos.

Por lo tanto, compararía cuánto mejora realmente la red neuronal respecto al árbol. Si la diferencia de rendimiento es pequeña, elegiría el árbol de decisión debido a su interpretabilidad. Si la diferencia fuera considerable, evaluaría la posibilidad de utilizar la red neuronal junto con métodos de interpretación y mecanismos de revisión humana.

En un sistema de créditos considero que lo más importante sería encontrar un equilibrio entre **precisión, transparencia, confiabilidad y posibilidad de revisar las decisiones**.